



Energieverbrauch von KI-Modellen

ARIC Brown Bag Session

Anselm Fehnker

11. Juni 2026





— **Anselm Fehnker**

— Senior AI Project Manager



Wie viel Energie hat ChatGPT im Jahr 2025 verbraucht?

1

Ähnlich viel wie
eine deutsche
Kleinstadt

2

Ähnlich viel wie
eine deutsche
Großstadt

3

Ähnlich viel wie
gesamt
Deutschland

Wo benötigt KI überall Energie?

Beim Trainieren und Bereitstellen von KI-Modellen wird an verschiedenen Stellen Energie verbraucht

Scope-1

Direkter Energieverbrauch



- KI-Modelle verbrauchen Energie bei Berechnungen
- Der Energieverbrauch hängt von Art und Größe des Modells ab

Scope-2

Indirekter Energieverbrauch



- Betreiben von Servern
- Kühlung, Netzwerk, Zwischenspeicher, ...
- Energieeffizienz (PUE) hängt vom Rechenzentrum ab

Scope-3

Energieverbrauch innerhalb der Wertschöpfungskette



- Training von KI-Modellen
- Herstellung von Hardware
- Bau von Rechenzentren
- Energieverbrauch auf Anwendungsseite

Beim Energieverbrauch von KI muss stark zwischen dem Training und der Anwendung (Inferenz) unterschieden werden

Training

Das KI-Modell lernt Regeln anhand von bereitgestellten Daten.

Unregelmäßiger Prozess mit hohem Energieverbrauch.

Beispiel Training GPT-3:
ca. 34 Tage Training auf großen GPU-Clustern

~1287 MWh Energieverbrauch

Inferenz


Das KI-Modell wendet die gelernten Regeln auf neue Daten an

Regelmäßiger Prozess mit geringem Energieverbrauch.

Beispiel Inferenz ChatGPT:
ca. 2,5 Milliarden Prompts pro Tag

~0.05 – 1.8 Wh pro Anfrage

Der Scope-1 Energieverbrauch hängt stark von der Aufgabenstellung und der Architektur des KI-Modells ab



Die Energieeffizienz für Scope-2 hängt davon ab, wie und wo KI-Modelle gehostet werden



On-Edge AI
PUE ~1.0



On-Premise Server
PUE 1.6 – 2.0



Colocation Datacenter
PUE 1.3 – 1.6



Hyperscaler Cloud
PUE 1.1 – 1.2

Die **Power Usage Effectiveness (PUE)** ist eine Kennzahl, die angibt, wie effizient ein Rechenzentrum seine Energie nutzt:

$$PUE = \frac{\text{Gesamtenergie Rechenzentrum}}{\text{Energieverbrauch der KI}}$$

A futuristic server room with rows of server racks on both sides, each filled with glowing blue and yellow lights. The ceiling is a complex grid of pipes and lights. In the center background, a large, glowing orange square sign with the letters 'AI' is mounted on the wall. Below the sign, there are three computer monitors on desks. The floor is highly reflective, showing the lights from the racks and ceiling.

Energieverbrauch von Sprachmodellen

Disclaimer: Einordnung der Angaben zum Energieverbrauch von Sprachmodellen

Der Energieverbrauch von Sprachmodellen ist keine konstante Größe.

Der genaue Verbrauch hängt von vielen Faktoren ab und kann stark variieren:

- a. Nutzungsabhängigkeit: Länge von Input und Output beeinflusst den Rechenaufwand.
- b. Technische Faktoren: Modellversion, eingesetzte Hardware sowie Effizienz des Rechenzentrums wirken sich auf den tatsächlichen Energieverbrauch aus.


Der Energieverbrauch von Sprachmodellen ist nicht transparent einsehbar.

Daten zum Verbrauch stammen meist aus zwei Arten von Quellen:

- a. Selbstauskünfte von Anbietern: Unternehmen veröffentlichen teilweise eigene Angaben zum Energieverbrauch ihrer Modelle. Dabei ist zu berücksichtigen, dass Anbieter selbst entscheiden, welche Messmethoden sie verwenden und welche Ergebnisse sie veröffentlichen.
- b. Wissenschaftliche Studien externer Forscher: In solchen Studien wird der Energieverbrauch von Sprachmodellen häufig auf Basis bestimmter Annahmen und Modellierungen abgeschätzt.

Wir haben verschiedene Studien und Anbieterangaben ausgewertet und ihre Ergebnisse vergleichend zusammengeführt. Dabei wurden Herkunft der Daten sowie die jeweiligen Mess- und Experimentbedingungen berücksichtigt; eine Auswahl zentraler Quellen findet sich im Anhang.

Sprachmodelle laufen derzeit größtenteils in großen Rechenzentren. On-Premise Lösungen sind nur selten möglich.



Verglichen mit anderen Alltagsaufgaben verbrauchen Sprachmodelle nicht überdurchschnittlich Energie



Small Language Model
LLaMA-3.2 1B

~0,21 Wh



Large Language Model
GPT-4o

~1,21 Wh



LLM mit Reasoning
Claude Opus (Extended Thinking)

~4,32 Wh



Google Suchanfrage

~0,3 Wh



iPhone Laden

~15 Wh



Kaffee kochen

~100 Wh



Nudeln kochen

~500 Wh

Die Nutzung von Sprachmodellen ist in den letzten Jahren rasant gestiegen





Figure 3: Weekly active ChatGPT users on consumer plans (Free, Plus, Pro), shown as point-in-time snapshots every six months, November 2022–September 2025.



Quelle: Aaron Chatterji, Thomas Cunningham, David J. Deming, Zoe Hitzig, Christopher Ong, Carl Yan Shan, and Kevin Wadman, "How People Use ChatGPT," NBER Working Paper 34255 (2025), <https://doi.org/10.3386/w34255>.

Der Stromverbrauch von Sprachmodellen hängt stark von der Art und Intensität der Nutzung ab



ChatGPT Jahresverbrauch 2024

$451 \text{ Mio} \cdot 1,21 \text{ Wh} \cdot 365 \approx 199 \text{ GWh}$

Äquivalent zu einer deutschen Stadt mit:
69.000 Einwohnern



ChatGPT Jahresverbrauch 2025

$2627 \text{ Mio} \cdot 1,21 \text{ Wh} \cdot 365 \approx 1\,160 \text{ GWh}$

Äquivalent zu einer deutschen Stadt mit:
401.000 Einwohnern



Möglichkeiten der Energiegewinnung

Verhandlungen mit Chevron: Microsoft plant Milliarden-Kraftwerk für KI-Rechenzentren - Aktien reagieren

01.04.26 22:08 Uhr



Microsoft führt Exklusivgespräche mit Chevron und Engine No. 1 über ein vorgeschlagenes 7 Milliarden-Dollar-Erdgaskraftwerk in West-Texas. So reagiert der Markt.

— Quelle: finanzen.net

13. Januar 2026

Meta Compute: Zuckerbergs 600-Milliarden-Invest für XXL-KI-Kraftwerke

Autor*in

Uli Weißgerber

Meta investiert massiv in KI-Infrastruktur: Das neue „Meta Compute“-Programm soll hunderte Gigawatt Rechenleistung schaffen und dem Konzern strategische Vorteile im KI-Wettlauf sichern.

Mark Zuckerberg setzt auf Größe – und zwar im industriellen Maßstab. Der Meta-CEO hat eine neue Initiative namens „Meta Compute“ angekündigt, die das Technologieunternehmen zum Infrastruktur-Giganten machen soll.

— Quelle: Business Punk

HOME > WIRTSCHAFT > EIGENE KRAFTWERKE FÜR KI-RECHENZENTREN: TRUMP WILL BIG TECH DAZU VERPFLICHTEN

Trump will, dass Big Tech eigene Kraftwerke für KI-Rechenzentren baut – zum Schutz vor hohen Stromkosten

Ellen Thomas
© 26 Feb. 2026



Präsident Donald Trump hielt am Dienstag seine jährliche Rede zur Lage der Nation vor dem Kongress. ©Nathan Howard/Getty Images

— Quelle: Business Insider

Vertrag für 25 Jahre

US-Atomkraftwerk geht für KI-Rechenzentrum von Google wieder ans Netz



Das Logo von Google ist auf dem Pavillon des Internet-Konzerns auf der Technik-Messe CES zu sehen. Ein US-Atomkraftwerk soll für ein KI-Rechenzentrum von Google wieder ans Netz.

Quelle: Andrej Sokolow/dpa

Anhören

Anwendungen mit Künstlicher Intelligenz brauchen immer mehr Energie. Die Tech-Konzerne setzen verstärkt auf Atomkraft. Auch Google will Strom über ein Kraftwerk in Iowa beziehen, das bereits abgeschaltet worden war. 2029 soll es wieder in Betrieb sein.

— Quelle: RND

KI-Rechenzentren können ihren Strom entweder aus dem Stromnetz beziehen oder eigenen Strom generieren




Aktuell der Standardfall




Überwiegend für Notfallstrom

Der Großteil an Energie für Rechenzentren wird in China und den USA verbraucht




Der Strom für Rechenzentren ist ein Strommix aus unterschiedlichen Energiequellen





Zukunftsperspektiven

Neben großen Sprachmodellen werden zunehmend auch kleinere, energieeffizientere Versionen der Modelle trainiert




Large Language Model

Optimiert für maximale Leistung

Läuft nur in großen Rechenzentren

Hoher Energieverbrauch




Small Language Model

Optimiert für Effizienz


Kann auch lokal gehostet werden

Geringerer Energieverbrauch


Es gibt immer mehr Modellarchitekturen, in denen nicht das gesamte Netzwerk, sondern nur die benötigten Teile rechnen



Es gibt vermehrt Alternativen wie KI-Modelle auf Hardware abseits von großen Rechenzentren gehostet werden können



Spezialisierte
KI-Chips



Language Processing
Units (LPUs)



Federated AI

Wie viel Energie hat das Generieren der Bilder für diese Präsentation verbraucht?

1

Ähnlich viel wie
**das Laden
eines iPhone**

2

Ähnlich viel wie
**das Kochen
von Nudeln**

3

Ähnlich viel wie
**2 Stunden
Fernsehen**

Fragen + Diskussion

KONTAKT

Anselm Fehnker

Senior AI Project Manager
fehnker@aric-hamburg.de



Quellensammlung (1/2)

Wissenschaftliche Quellen:

- [1] N. Jegham, M. Abdelatti, L. Elmoubarki, und A. Hendawi, „How Hungry is AI? Benchmarking Energy, Water, and Carbon Footprint of LLM Inference“, 15. Juli 2025, *arXiv*: arXiv:2505.09598. doi: 10.48550/arXiv.2505.09598.
- [2] Z. Ji und M. Jiang, „A systematic review of electricity demand for large language models: evaluations, challenges, and solutions“, *Renewable and Sustainable Energy Reviews*, Bd. 225, S. 116159, Jan. 2026, doi: 10.1016/j.rser.2025.116159.
- [3] A. S. Luccioni *u. a.*, „Estimating the Carbon Footprint of BLOOM, a 176B Parameter Language Model“.
- [4] A. Chatterji *u. a.*, „How People Use ChatGPT“, Sep. 2025, doi: 10.3386/w34255.

Quellensammlung (2/2)

Internetquellen:

- <https://epoch.ai/gradient-updates/how-much-energy-does-chatgpt-use> (Accessed 18.03.2026)
- <https://hannahritchie.substack.com/p/carbon-footprint-chatgpt> (Accessed 18.03.2026)
- <https://www.ingenieur.de/technik/fachbereiche/energie/chatgpt-als-energiefresser-wie-der-ki-bot-die-energie-von-31-millionen-elektroautos-verschlingt/> (Accessed 18.03.2026)
- <https://www.tagesschau.de/wirtschaft/energie/kuenstliche-intelligenz-energieverbrauch-100.html> (Accessed 18.03.2026)
- <https://mistral.ai/news/our-contribution-to-a-global-environmental-standard-for-ai> (Accessed 19.03.2026)