



Lautmaler

Conversational AI

Technologischer Durchbruch vs. Vertrauensproblem

Manja Baudis &
Dr. Jutta Stock



Agenda



1

Einstieg

Die Klarna-Story

2

Der Durchbruch

Was Conversational AI heute technisch und wirtschaftlich leistet

3

Das Vertrauensproblem

und wie wir damit umgehen – 5 konkrete Dimensionen


4

Unser Fazit

Früher

... mussten wir jede erwartete Formulierung, jeden Slot, jeden Dialogpfad selbst beschreiben und implementieren. Die Maschine hat lediglich das verstanden, verarbeitet und ausgegeben, was wir ihr explizit beigebracht hatten.

Heute übernehmen KI-Modelle die Dialogstrategie und die Formulierungen, auch für Situationen, die wir nie vorgesehen haben.



Technologischer Durchbruch

Reasoning

Modelle „denken“ intern mehrstufig und lösen dadurch komplexere Aufgaben besser

Von der Konversation zu Aktion

Systeme rufen Werkzeuge auf, bedienen APIs, planen mehrstufig und führen Aktionen aus

Verbesserte Alignment Verfahren

Modelle werden hilfsbereiter – aber auch anfälliger für bestimmte Verzerrungen



Ein Vergleich



Dimension	Früher	Heute
Sprachverständnis	Grammatiken, Keyword-/Pattern-Matching, händisch gepflegte Trainingsphrasen pro Intent	Generalisiertes Sprachverständnis, erfasst Phrasierungsvarianten, Tippfehler, Dialekt, Code-Switching implizit
Architektur	Mehrstufig: ASR → Intent-Klassifikation → Slot-Filling → separater Dialogmanager → TTS	Ein Modell übernimmt Verständnis, Kontextbezug und Generierung weitgehend end-to-end
Abdeckung (long tail)	Kann unvorhergesehene Events nur mit generischem Errorhandling abfangen	Generalisiert auf ungesehene Formulierungen, teils sogar neue Aufgabentypen
Entwicklungsaufwand	Pro Intent: Trainingsphrasen sammeln, labeln, Slots definieren, Dialogflow explizit als State Machine modellieren → Wochen bis Monate	Instruktion/Prompt + wenige Beispiele + Grounding-Dokumente → oft Tage bis Wochen
Kontext	Expliziter, meist eng begrenzter Dialogzustand, hart codiert	Kontextfenster hält den gesamten bisherigen Dialog; Themenwechsel und Rückbezüge
Weltwissen	Nur das, was explizit in Wissensbasis/Backend hinterlegt wurde	Breites, implizit gelerntes Weltwissen aus dem Pretraining
Handlungsfähigkeit	Aktionen nur über fest verdrahtete Backend-Calls an vordefinierten Punkten im Flow	Agentic Tool-Use: Modell plant selbstständig, welches Tool/welche API wann und in welcher Reihenfolge aufgerufen wird
Portierbarkeit	Weitgehender Neubau der NLU-Pipeline und des Dialogflows nötig	Gleiches Basismodell, neue Domäne über Prompting, Beispiele, RAG oder leichtes Fine-Tuning anpassbar

Ein paar Zahlen

- **91%** halten KI für die wichtigste Zukunftstechnologie, nur noch 8 % halten sie für überschätzten Hype
- KI wird bis **2027 über die Hälfte aller Servicefälle bearbeiten** (heute ca. 30 %)
- **67 %** der deutschen Unternehmen bauen derzeit ihren Conversational-AI-Einsatz aus
- **92,5 %** aller Chatbots sind noch regelbasiert, 7,5 % mit LLM-Fähigkeiten





Das Vertrauensproblem


Kein neues Phänomen bei Conversational Interfaces.

Früher: deterministische Systeme
Feste Pfade & erkennbare Grenzen
„Kann der Bot das überhaupt?“

Heute: LLM-basiert
Ton: selbstsicher, flüssig, professionell
"Kann ich dieser Antwort trauen?"




Ein Vergleich



Dimension	Früher	Heute
Vorhersagbarkeit	Deterministisch, reproduzierbar	Probabilistisch, dieselbe Frage kann unterschiedlich beantwortet werden
Transparenz	Entscheidungspfad im Prinzip vollständig auditierbar	Black Box: Entstehung einer Antwort ist nicht vollständig rekonstruierbar
Fehlermodus	Sichtbares Scheitern („das verstehe ich nicht“)	Unsichtbares Scheitern: Eine falsche Antwort klingt genauso überzeugend wie eine richtige
Erwartung	Nutzende lernen, sich der Maschine anzupassen	Maschine wirkt menschlich genug, dass Nutzende erwarten, sie verstehe wie ein Mensch
Vertrauensrisiko	Unterschätzung der Fähigkeiten (zu wenig Vertrauen)	Überschätzung der Zuverlässigkeit: Overtrust, Sykophanz-Anfälligkeit
Angriffsfläche	Klar begrenzt auf definierte Eingabepfade	Offen für Prompt Injection, da Instruktion und Dateninhalt nicht strukturell getrennt sind

Conversational AI Design

Bewährtes bleibt wichtig:



Vertrauensproblem bei LLMs

Die 5 Dimensionen

- Halluzinationen & Faktentreue
- Sykophanz & Overtrust
- Bias & Diskriminierung
- Datenschutz & Sicherheit
- Regulierung & Haftung



Halluzinationen & Faktentreue

LLM's erzeugen Sprache nach **Wahrscheinlichkeiten** und liefern nicht unbedingt geprüfte **Wahrheiten**

Eine Bot-Antwort kann überzeugend und präzise klingen, aber trotzdem komplett erfunden sein

Ein Problem für beide Seiten einer Kund*innenservice-Beziehung:

- Endkund*innen: können nicht einschätzen, ob sie einer Antwort vertrauen können
- Unternehmen: müssen sicherstellen, dass nur Fakten an Ihre Kund*innen weitergegeben werden



Maßnahmen

Grounding (RAG)


Soll sicherstellen, dass die Antworten eines Modells mit einer vertrauenswürdigen externen Quelle übereinstimmen und nicht allein auf der Grundlage von Trainingsdaten generiert werden.

Hallucination Detection

Ein zweites Modell (oder ein erneuter Aufruf) bewertet, ob die generierte Antwort aus den Quelldokumenten abgeleitet werden kann. Wenn die Antwort etwas enthält, das in den Quellen nicht vorkommt, wird sie als Halluzination markiert.

Weitere Maßnahmen

Hochriskante Themen als deterministische Antworten



Sycophancy & Overtrust

Sykophanz/Sycophancy (übermäßige Zustimmung)

Alignment-Verfahren machen Modelle freundlicher, hilfsbereiter, zustimmender. Und sie neigen dazu, die Sichtweise der Nutzer*innen zu bestätigen, auch wenn die sachlich falsch ist.

Overtrust

Nutzer*innenseite desselben Phänomens:

Menschen übertragen auf ein flüssig klingendes System mehr Kompetenz, als es tatsächlich hat.



Maßnahmen

Qualitätssicherung

gezielt falsche Behauptungen in Testdialoge einspeisen und prüfen

Prompting

Sachliche Richtigkeit hat Vorrang vor wahrgenommener Nutzer*innenzufriedenheit

Persona

Sichtbare/hörbare Korrekturen ("Das sehe ich anders, weil...")


Zurückhaltende Persona-Gestaltung

KI-Kennzeichnung

Zu Gesprächsbeginn (ohnehin Pflicht EU AI Act) macht den Automatisierungs-Rahmen bewusst

Human Handover

Emotionale oder strittige Themen konsequent an Menschen weiterleiten



Bias & Diskriminierung

Bias

Sprachmodelle lernen statistische Muster aus riesigen Trainingskorpora, die gesellschaftliche Verzerrungen unweigerlich mit abbilden

Diskriminierung

KI-Systeme benachteiligen nachweislich bestimmte Gruppen (besonders deutlich bei Scoring-Algorithmen)

Besonderheit Voice

Spracherkennung von non-native-Speakern, Dialekten etc.




Maßnahmen

Bias Audits

Prüfen, ob sich Ausgaben ändern, wenn einzelne Attribute wie Wohnort o.ä. verändert werden

ASR

Bot in diversen Sprachen anbieten



Datenschutz & Sicherheit

Sobald ein Bot nicht mehr nur *spricht*, sondern *handelt* (als Agent mit Tool-Zugriff), ändern sich die Risiken fundamental.


Ein Chatbot, der eine falsche oder schräge Antwort gibt, ist vermutlich peinlich und geht manchmal viral. Ein Agent, der auf Basis derselben falschen Annahme einen Vertrag kündigt oder eine Datenbank löscht, wird zu einem Sicherheitsproblem.



Maßnahmen

Die Schwachstellen liegen selten im Sprachmodell selbst, sondern im "Drumherum", bei Berechtigungen, Datenquellen, fehlende Kontrollen.

- konsequente Umsetzung von Datenschutzstandards
- Granulare Tool-Berechtigungen
- Session-basierte Datenminimierung
- Explizite Bestätigungsschritte
- Wahlfreiheit
- Hybride Architektur statt vollständig agentischer Freiheit



Regulierung und Haftung

Seit dem **2. August 2026** greifen die Transparenzpflichten **EU AI Acts**.


- Chatbots müssen sich unaufgefordert als KI zu erkennen geben (nicht versteckt im Impressum)
- KI-generierte Inhalte müssen maschinenlesbar gekennzeichnet werden, Deepfakes offengelegt werden.
- Verstöße können mit Bußgeldern geahndet werden



Maßnahmen

Entscheidungen, Verantwortlichkeiten, Kontrolle

- Klare Verantwortlichkeiten in der KI-Lieferkette (wer ist wofür verantwortlich und wer haftet wofür)
- Meldeprozesse für Sicherheitsvorfälle
- Regelmäßiges Screening der eigenen Risiko-Einstufung nach AI Act
- Dokumentations- und Auditierbarkeitspflicht



Fazit und Ausblick



Hybrid statt Entweder-oder:

KI für Volumen, Menschen für Urteilsvermögen

Durchbruch & Vertrauensproblem:

Zwei Seiten derselben Entwicklung

Vertrauen als Designprinzip:

Von Anfang an mitdenken



Lautmaler


Danke!

Manja Baudis



&

Dr. Jutta Stock



Quellen

[bitkom](#)

- 14. September 2026, Erhebungszeitraum KW 28–33/2026
- n=603 Unternehmen ab 20 Beschäftigten, telefonisch befragt

[Salesforce, State of Service Report,](#)

- 25. April–6. Juni 2025, veröffentlicht 13.11.2025
- n=6.500 weltweit, davon 300 in Deutschland, doppelt anonymisierte Befragung,

[Rasa, State of Conversational AI Report,](#) 2026

[Parloa, The State of CX Report,](#) April 2026

[Capterra,](#)

- 2.307 Kundenservice-Mitarbeitern weltweit, davon 187 aus Deutschland

