

KLINISCHE KI · MENSCHLICHE AUFSICHT

Human in the Loop:

Kontrolle oder Kontrollgefühl?

Drei Aufsichtsmodelle, eine menschliche Psychologie, und warum gute KI die Kontrolle schwerer macht statt leichter.

PD Dr. med. habil. Witold H. Polanski

Neurochirurgie & KI-Taskforce, Universitätsklinikum Dresden
Chief Medical Officer, Simply Onno GmbH (Berlin)

Ein unbequemes Muster

+16%

GPT-4 allein schlägt Ärzt:innen in der diagnostischen Begründung.

Goh et al., JAMA Netw Open 2024

±0%

Ärzt:innen mit GPT-4 sind nicht besser als ohne (76 % vs. 74 %).

Goh et al., JAMA Netw Open 2024

-14%

Genauigkeit, sobald das Modell falsch liegt, trotz 20 h KI-Training.

Qazi et al., NEJM AI 2026

Das Werkzeug ist stark. Die Kombination Mensch und Werkzeug ist es nicht (automatisch).

Die Standardantwort der Institutionen


” Hochrisiko-KI muss von natürlichen Personen **wirksam beaufsichtigt** werden und diese müssen sich der Neigung bewusst bleiben, sich **automatisch auf die Ausgabe zu verlassen**.

Artikel 14, EU AI Act (Verordnung 2024/1689). Das Gesetz benennt den Automation Bias selbst.

Klingt beruhigend. Aber „in der Schleife“ ist kein einzelnes Setting: es sind drei Architekturen, und die Wahl einer davon verschiebt das Versagen, statt es zu beseitigen.

Wo genau steht der Mensch?

Dieselbe KI-Pipeline, drei Positionen des Menschen. Das ist der ganze Unterschied.



Im Fluss: prüft jede Ausgabe, bevor gehandelt wird.

Analogie: Lektorat, jede Zeile wird gegengelesen.



Neben dem Fluss: überwacht das autonome System, greift nur bei Abweichung ein.



Analogie: Bademeister:in, greift nur bei Gefahr ein.

Über dem Fluss: setzt Regeln und Schwellen, sieht keine Einzelausgabe.

Analogie: Aufsichtsrat und QM-Gremien, setzt Regeln und liest Berichte.



DIE KERNTHESE

Der Aufsichtstrugschluss

Die Annahme, dass ein Mensch, ob **in, neben oder über** dem Workflow, die Fehler in dessen Ausgabe zuverlässig erkennt und korrigiert.

Strukturell, nicht persönlich. Der Trugschluss sitzt in der Architektur, nicht im Personal, und überlebt jede Schulung. Gerade flüssige, plausible Ausgabe ist der Input, der die Grenzen menschlicher Verifikation offenlegt.

Warum der Mensch die Fehler nicht fängt

Vier kognitive Mechanismen. Keiner davon ist ein Mangel an Sorgfalt.



Automatisierungsverzerrung

AUTOMATION BIAS · HITL

Wir verlassen uns auf die Ausgabe, gerade weil sie plausibel wirkt. Der EU AI Act benennt diese Neigung selbst.

Beispiel: Wie beim Navi: wir folgen der Ansage, selbst wenn die Straße erkennbar gesperrt ist.



Zustimmen ist billiger als Prüfen

VERIFIKATIONSLAST · HITL

Je schwerer eine Aussage unabhängig zu prüfen ist, desto eher wird sie übernommen (Lyell & Coiera).

Beispiel: Einen KI-Arztbrief Satz für Satz gegen die Akte zu prüfen dauert oft länger, als ihn selbst zu schreiben.



Wachsamkeit zerfällt

VIGILANZ · HOTL

Beim Überwachen seltener Ereignisse sinkt die Aufmerksamkeit binnen Minuten. Überwachen ist paradox anstrengend.

Beispiel: Mackworths Radar-Beobachter (1948): nach 30 Minuten bricht die Trefferquote messbar ein.



Seltene Fehler werden übersehen


LOW-PREVALENCE · ÜBERGREIFEND

Je besser die KI, desto seltener und unauffälliger der Fehler. Die Entdeckung wird schwerer, nicht leichter (Wolfe, 2007).

Beispiel: Gepäckkontrolle am Flughafen: je seltener verbotene Objekte, desto öfter werden sie übersehen.

Das Paradox zweiter Ordnung

Bessere KI bedeutet seltenere Fehler, und seltene Fehler entgehen der menschlichen Wahrnehmung.



Die Folge

Verbesserung macht die Entdeckung schwerer, nicht leichter. Bansal et al. und Bastani & Cachon zeigen formal: der Anreiz, der Wachsamkeit trägt, steigt umgekehrt zur Fehlerrate und wird genau dann prohibitiv teuer, wenn die KI gut wird.

Illustrativ; Low-Prevalence-Effekt nach Wolfe et al., J Exp Psychol Gen 2007.

Nicht „Halluzination“, sondern fünf Fehlerklassen

Für die Aufsichtsfrage ist ein einziger Sammelbegriff zu grob.



Faktische Halluzination

Erfundene Fakten, Namen, Dosierungen, Referenzen. Die bekannte, gut adressierte Klasse.

Beispiel: Der Entlassbrief nennt einen MRT-Kontrolltermin, der nie vereinbart wurde.



Semantischer Drift

UNTERSCHÄTZT

Weichgespülte Qualifizierer und Kalibrierungs-Mismatch, ohne dass ein Fakt erfunden wird.

Beispiel: „Leichte Veränderung“, obwohl die Befundlage auf moderat bis schwer deutet.



Sycophancy

Das Modell stimmt der vermuteten Überzeugung der Nutzer:in zu, auch wenn sie falsch ist (Fanous, AIES 2025).

Beispiel: Die Ärzt:in vermutet Diagnose X; das Modell bestätigt sie gegen die Datenlage.



Omission

Klinisch Kritisches wird weggelassen, ohne Oberflächensignatur und für Detektoren unsichtbar.

Beispiel: Die dokumentierte Penicillin-Allergie fehlt im Entlassbrief.



Format- und Strukturdrift

Schema-Verletzungen und Teil-Compliance, die nachgelagert die Bedeutung verändern.

Beispiel: Die Dosierung steht im Freitext statt im Medikationsfeld; das Folgesystem liest sie nicht.

Semantische Drift

Die KI schreibt:

„... am ehesten vereinbar mit *milder* interstitieller Veränderung.“

Die Token-Verteilung darunter:

konzentriert sich auf **moderate bis schwere** Pneumonitis.

Kein Fakt ist erfunden. „Mild“ ist ein stilistischer Prior des Modells, keine kalibrierte Schätzung. Eine Halluzinations-Metrik fängt das nie.



Jetzt messbar

Ji et al. (EMNLP 2025): Die verbale Unsicherheit folgt einer linearen Richtung im Residual-Stream, entkoppelt von der semantischen. Der Mismatch sagt Halluzinationen besser vorher.



HITL: aus Prüfen wird Abnicken

Der Mensch sitzt im Fluss und soll jede Ausgabe validieren. Unter **Automation Bias** und hoher **Verifikationslast** wird aus dem Prüfen ein Ratifizieren.

82,3 %

Trefferquote sehr erfahrener Radiolog:innen mit korrekter KI-Empfehlung.

45,5 %

Dieselben Expert:innen mit falscher KI-Empfehlung. 37% schlechter, die Erfahrung nicht verhindert.

Dratsch et al., Radiology 2023 · 50 Mammographien, fiktive BI-RADS-Vorschläge

Der Mechanismus

Je schwerer eine Aussage unabhängig zu prüfen ist, desto eher wird sie übernommen (Lyell & Coiera). Narrativer Freitext ist der Extremfall: in einem Arztbrief wirkt jeder Hedge für sich plausibel. Am stärksten exponiert sind faktische Halluzination und Sycophancy.



HOTL: Aufsicht per Ausnahme

Der naive Fall: der Mensch beobachtet ein autonomes System und wartet auf Ärger. Hier wirkt der **Vigilanzverfall**: Aufmerksamkeit ist nicht abrufbar, wenn das Ereignis selten ist.




Human-on-the-loop vereint die schlechtesten Eigenschaften beider Kontrollmodi: Menschen langweilen sich beim Beobachten autonomer Systeme, und die Aufmerksamkeit sinkt genau im falschen Moment.

Kaspersen & Leins, 2021



HOTL: Aufsicht per Ausnahme



Mackworths Clock Test (1948) zeigt: die Aufmerksamkeit zerfällt innerhalb von Minuten, wenn Ziele selten sind. Bei Maschinengeschwindigkeit hat das System längst gehandelt, bevor der Mensch eingreift. Am stärksten exponiert sind die ungeflaggten Klassen: semantische Drift, Omission, Formatdrift.



HATL: das System beaufsichtigen, nicht die Entscheidung

Der Mensch verlässt die Einzelentscheidung ganz. Gegenstand ist das eingesetzte System. Quality-, Safety- und Data-Professionals tragen die Arbeit mit, und die Instrumente brauchen kein Lesen von Einzelfällen.



Gut gemacht

Real-world-Monitoring, Audit, Second-Model-Checks und Anomalie-Flags, bis zum sofortigen Modell-Rollback. Fängt, was kein In-Loop-Reviewer fangen kann.



Schlecht gemacht

Governance-Theater: Audit-Kriterien auf Annahmen statt beobachtetes Verhalten kalibriert, Outcome-Proxies zu grob, Korrekturzyklen hinken dem Deployment hinterher.



Drift bleibt unsichtbar

Auf Outcome-Proxies unsichtbar. Handhabbar erst, wenn Audits die Ausgaben linguistisch sampeln, nicht nur Telemetrie auswerten.

Diese Ebene wirkt nur, wo Deployment-Fehler die Aufsichtsstelle tatsächlich erreichen (Laux 2024). Wo Outcome-Telemetrie existiert, lassen sich Halluzination und Omission und semantischer Drift auditieren.

Risiko wird verschoben, nicht beseitigt

Welche Fehlerklasse trifft welche Aufsichtsebene am härtesten?

Fehlerklasse	HITL	HOTL	HATL
Faktische Halluzination	Hoch	Mittel	Niedrig
Semantische Drift	Hoch	Sehr hoch	Sehr niedrig
Sycophancy	Sehr hoch	Mittel	Niedrig
Omission	Mittel-hoch	Hoch	Mittel
Format- und Strukturdrift	Niedrig-mittel	Hoch	Mittel

Gegenmaßnahmen, die zur Fehlerklasse passen

Strukturell heißt: am Workflow ansetzen, nicht an der Tugend.



Faktische Halluzination

Quellengebundenes Retrieval, Zitationspflicht am Claim, deterministische Prüfung gegen Wissensbasis.



Semantische Drift

Mismatch-Monitoring verbal vs. semantisch, kalibrierungsbewusste UI, Stresstest durch Umformulierung.



Sycophancy

Pre-Commitment: Erstbefund vor KI-Sicht. Strukturierte Widerspruchs-Framings.



Omission

Vollständigkeits-Checklisten aus dem Quelldokument, Coverage-Metriken.



Format- und Strukturdrift

Schema-validierte Ausgaben mit harter Zurückweisung bei Verletzung.



Wann Aufsicht doch funktioniert

Die Gegenevidenz ernst nehmen und die Randbedingungen benennen.



AMIE (McDuff et al., Nature 2025): An 302 anspruchsvollen NEJM-Fällen lieferte das Modell treffsicherere Top-10-Differenzialdiagnosen als Kliniker:innen allein, und AMIE-gestützte Kliniker:innen schlugen die Suchmaschinen-gestützten.

Was AMIE hatte und der Routine-Alltag nicht hat:



Diskrete Rangliste

Geordneter Listen-Output statt freier Erzähltext.



Niedrige Verifikationslast

Leicht unabhängig prüfbar, im Sinne von Lyell-Coiera.



Kalibrierung

Gut kalibrierte Konfidenz und methodische Instrumentierung.

Wo dieses Gerüst fehlt, etwa bei Entlassbriefen, Einwilligungstexten und Patient:innenkommunikation, **invertiert die Architektur und Aufsicht kollabiert zum Abnicken.**



Aus der eigenen Praxis: Simply Onno

TRANSPARENZ: EIGENES UNTERNEHMEN · CMO



Onno übersetzt medizinische Befunde in verständliche Sprache für Patient:innen. Bei 80.000+ verarbeiteten Berichten kann kein Mensch jede Ausgabe prüfen, also haben wir die Architektur umgedreht.

Die Maschine sucht aktiv

Fünf spezialisierte Judges, einer je Fehlerklasse. Parallel auf jeder Ausgabe, mit strikten Zuständigkeits-Firewalls gegen Doppelbestrafung.

Aktive Suche statt passiver Bewertung. Das Prompt-Muster „Finde den Fehler!“ liefert gründlichere Ergebnisse als holistisches Benoten.

Verharmlosung ist explizites Jagdziel. Harte Prompt-Grenzen verbieten zugleich Diagnose und Therapieempfehlung.

Der Mensch prüft gezielt

Triage statt Totalkontrolle. Score ≤ 3 erzwingt menschliches Review, Score 4 bei geringer Konfidenz ebenso, 5er-Fälle als Stichprobe zur Kalibrierung.

Sensitivität vor Präzision. Ein Fehlalarm kostet einen Blick, ein übersehener Fehler kostet Patient:innenvertrauen.

Wer prüft die Prüfer? Gold-Set-Validierung gegen doppelt human-gelabelte Fälle.

Die Maschine filtert, der Mensch entscheidet. Die Vorfilterung erhöht die Fehlerdichte im Review-Stapel und entschärft so das Low-Prevalence-Problem.

Drei Forderungen



Forschende

Semantische Drift als erstklassiges Evaluationsziel behandeln, gleichrangig zur Halluzination, und die Instrumentierung dafür entwickeln.



Regulierer

Über Artikel 14 hinaus die empirischen Signale spezifizieren, an denen Aufsicht kalibriert wird. WHO-2024-Feedbackpflicht aufgreifen.



Institutionen

Aufsicht konfigurieren, nicht eine Ebene wählen: Management-Audit als Konstante, Einzelfälle nach Risikograd, Verifikationskomplexität und Latenztoleranz zwischen gezieltem Review und autonomem Lauf eskalieren.

ZUM SCHLUSS

„Human in the loop“: Dabeisein ist nicht Kontrolle.

Wirksame Kontrolle ist eine Frage des Designs, nicht der Aufmerksamkeit.

PD Dr. med. habil. Witold H. Polanski

witold.polanski@ukdd.de · Universitätsklinikum Dresden ·

Simply Onno GmbH



Quellen

Im Vortrag zitierte Arbeiten.

KLINISCHE EVIDENZ

Goh E, Gallo R, Hom J, et al. Large language model influence on diagnostic reasoning: a randomized clinical trial. JAMA Netw Open 2024; 7: e2440969.

Qazi IA, Ali A, Khawaja AU, et al. Automation bias in large language model-assisted diagnostic reasoning among physicians trained in AI literacy. NEJM AI 2026; 3(5): A10a2501001.

Dratsch T, Chen X, Rezazade Mehrizi M, et al. Automation bias in mammography: the impact of AI BI-RADS suggestions on reader performance. Radiology 2023; 307: e222176.

McDuff D, Schaekermann M, Tu T, et al. Towards accurate differential diagnosis with large language models. Nature 2025; 642: 451-57.

HUMAN FACTORS & KOGNITION

Lyell D, Coiera E. Automation bias and verification complexity: a systematic review. J Am Med Inform Assoc 2017; 24: 423-31.

Mackworth NH. The breakdown of vigilance during prolonged visual search. Q J Exp Psychol 1948; 1: 6-21.

Wolfe JM, Horowitz TS, Van Wert MJ, et al. Low target prevalence is a stubborn source of errors in visual search tasks. J Exp Psychol Gen 2007; 136: 623-38.

Buçinca Z, Malaya MB, Gajos KZ. To trust or to think: cognitive forcing functions can reduce overreliance on AI. Proc ACM Hum-Comput Interact 2021; 5: 188.

KI-EVALUATION & ÖKONOMIE

Bansal G, Nushi B, Kamar E, et al. Is the most accurate AI the best teammate? Optimizing AI for teamwork. Proc AAAI Conf Artif Intell 2021; 35: 11405-14.

Bastani H, Cachon GP. The human-AI contracting paradox. SSRN Working Paper 5962739; 2025.

Ji Z, Yu L, Koishekenov Y, et al. Calibrating verbal uncertainty as a linear feature to reduce hallucinations. Proc EMNLP 2025: 3769-93.

Fanous A, Goldberg J, Agarwal A, et al. SycEval: evaluating LLM sycophancy. Proc AAAI/ACM Conf AI Ethics Soc 2025; 8(1): 893-900.

GOVERNANCE

Europäisches Parlament, Rat der EU. Verordnung (EU) 2024/1689 (Artificial Intelligence Act), Artikel 14. OJ L, 12. Juli 2024.

World Health Organization. Ethics and governance of artificial intelligence for health: guidance on large multi-modal models. Genf, Januar 2024.

Kaspersen A, Leins K. Seven myths of using the term „human on the loop“. Carnegie Council for Ethics in International Affairs, 2021.